

Tourism Forecast AI

Prévision de la demande touristique et recommandations de destinations à promouvoir

Projet final de Master – Gouvernance des Données et Intelligence Artificielle

Périmètre : Data Engineering, Data Quality, Machine Learning, BI, Gouvernance

Livrable : Rapport de synthèse professionnel

Outil dashboard : Streamlit, Plotly, Scikit-learn

Modèle retenu : Gradient Boosting + lag features

Table des matières

Executive Summary	4
1 Contexte et besoin métier	5
1.1 Problématique	5
1.2 Objectifs du projet	5
2 Architecture du projet	6
2.1 Organisation du repository	6
2.2 Principes d'architecture	6
3 Sources de données	8
3.1 Fichiers utilisés	8
3.2 Lecture critique des données	8
4 Data Engineering et chargement robuste	9
4.1 Pipeline de chargement	9
4.2 Traçabilité	9
5 Analyse exploratoire des données	10
5.1 Axes d'analyse	10
5.2 Constats principaux	10
6 Nettoyage et gouvernance	11
6.1 Règles de nettoyage	11
6.2 Mapping des destinations	11
7 Construction de la GOLD DATA	12
7.1 Granularité	12
7.2 Variables dérivées	12
7.3 Formule de priorisation	12
8 Partie F – Modélisation IA et forecasting temporel	13
8.1 Objectif de modélisation	13
8.2 Type de problème IA	13
8.3 Feature engineering temporel	13
8.4 Approches comparées	14
8.5 Résultats des modèles	14

8.6	Choix du modèle	14
8.7	Lecture critique	14
9	Moteur de recommandation métier	16
9.1	Contraintes intégrées	16
9.2	Top recommandations	16
9.3	Interprétation métier	16
10	Dashboard Streamlit	17
10.1	Objectif	17
10.2	Pages principales	17
10.3	Exports	17
11	Gouvernance et dictionnaire de données	18
11.1	Principes de gouvernance	18
11.2	Exemples de règles qualité	18
12	Limites et biais	19
12.1	Limites des données	19
12.2	Limites des modèles	19
13	Recommandations futures	20
	Conclusion	21
A	Annexes techniques	22
A.1	Commande de lancement	22
A.2	Fichiers de sortie principaux	22
A.3	Extrait de la logique de cible	22
A.4	Extrait de rolling features sans fuite	22

Liste des tableaux

1	Synthèse des résultats clés	4
3.1	Sources du projet	8
6.1	Décisions de nettoyage	11
7.1	Variables dérivées principales	12
8.1	Approches de forecasting comparées	14
8.2	Performance des modèles	14
9.1	Top 10 recommandations marketing	16
11.1	Exemples de règles qualité	18

Executive Summary

Ce projet vise à prévoir la demande touristique future par pays et à recommander les destinations à promouvoir en priorité. Le cas d’usage combine des enjeux de Data Engineering, Data Quality, gouvernance des données, Machine Learning temporel, Business Intelligence et recommandation métier.

Le projet a été construit selon une logique professionnelle de type cabinet de conseil : conservation des données brutes, pipeline reproductible, GOLD DATA, dictionnaire de données, modèles de forecasting, moteur de recommandation, dashboard exécutif Streamlit et documentation. Les données initiales contiennent volontairement des incohérences : casse des pays, granularités hétérogènes, budgets inconnus, contradictions campagne et cible textuelle non exploitable. Ces anomalies ont été traitées comme des éléments de gouvernance et non comme de simples erreurs techniques.

TABLE 1 – Synthèse des résultats clés

Indicateur	Résultat
Nombre de lignes GOLD DATA	160 destinations pays–ville
Nombre de pays	8 pays : France, Germany, Italy, Japan, Morocco, Portugal, Spain, USA
Meilleur modèle	Gradient Boosting + lag features
MAE	6.85
RMSE	8.67
MAPE	7.30%
R^2	0.86
Top recommandation	Fès, Morocco

1 Contexte et besoin métier

1.1 Problématique

L'objectif métier est d'aider une équipe marketing touristique à répondre à la question suivante :

Quels pays et quelles destinations doivent être promus en priorité compte tenu de la demande future, de la qualité perçue, du sentiment en ligne, du coût, de la météo et de l'historique campagne ?

La décision marketing ne peut pas se limiter au volume historique de visiteurs. Une destination attractive mais coûteuse, mal notée ou exposée à une météo défavorable ne doit pas être priorisée de la même manière qu'une destination en croissance avec bonne qualité perçue et bon potentiel de campagne.

1.2 Objectifs du projet

Les objectifs opérationnels sont :

- charger automatiquement des fichiers CSV, Excel et JSON ;
- profiler la qualité des données ;
- nettoyer les référentiels pays et destinations ;
- construire une GOLD DATA exploitable ;
- prévoir la demande touristique future par pays ;
- recommander les destinations à promouvoir ;
- restituer les résultats dans un dashboard exécutif ;
- documenter les limites, biais et règles de gouvernance.

2 Architecture du projet

2.1 Organisation du repository

Le projet a été structuré selon une architecture professionnelle séparant les données brutes, transformées, GOLD, le code source, les notebooks, le dashboard et les rapports.

Listing 2.1 – Architecture du repository

```
project/  
    data/  
        raw/  
        processed/  
        gold/  
    notebooks/  
        01_EDA.ipynb  
        02_Cleaning.ipynb  
        03_GoldData.ipynb  
        04_Model.ipynb  
    src/  
        preprocessing.py  
        feature_engineering.py  
        modeling.py  
        recommendation.py  
        city_mapping.py  
    dashboard/  
        app.py  
    reports/  
    docs/  
    models/  
    requirements.txt  
    README.md
```

2.2 Principes d'architecture

- **Raw immutable** : les fichiers sources sont conservés sans modification.
- **Processed auditable** : chaque nettoyage est sauvegardé et documenté.
- **Gold analytique** : une table finale pays–destination sert de socle commun pour la BI, l'IA et la recommandation.
- **Code modulaire** : les transformations sont isolées dans des modules Python maintenables.

— **Reproductibilité** : le script `run_pipeline.py` régénère les sorties principales.

3 Sources de données

3.1 Fichiers utilisés

TABLE 3.1 – Sources du projet

Fichier	Description	Format
01_destinations_brut.csv	Destinations, attractivité, coût, rating, visiteurs	CSV
02_signaux_marche.xlsx	Signal mensuel de demande par pays	Excel
03_reviews_reseaux.json	Avis sociaux, sentiment et score	JSON
04_facteurs_externes.csv	Prix de vol et météo	CSV avec séparateur ;
05_cible_recommandation.csv	Texte de consigne non tabulaire	CSV texte
06_campaign_history.json	Historique campagne, budget, ROI, statut	JSON

3.2 Lecture critique des données

Le fichier `05_cible_recommandation.csv` ne constitue pas une table analytique exploitable. Il contient une consigne textuelle et non une variable cible structurée. La cible de modélisation a donc été construite à partir des données temporelles disponibles : le signal mensuel de demande par pays.

Cette décision est importante d'un point de vue gouvernance : une donnée fournie ne doit pas être considérée comme correcte ou exploitable sans contrôle préalable.

4 Data Engineering et chargement robuste

4.1 Pipeline de chargement

Le pipeline de chargement détecte les formats de fichiers et applique les lecteurs adaptés :

- CSV avec détection du séparateur ;
- Excel via `pandas.read_excel` ;
- JSON via normalisation en table ;
- journalisation des dimensions, colonnes et types ;
- gestion des erreurs avec logs.

4.2 Traçabilité

Toutes les sources sont copiées dans `data/raw`. Les transformations ne modifient jamais directement les sources. Les sorties nettoyées sont stockées dans `data/processed`, et la table finale dans `data/gold`.

5 Analyse exploratoire des données

5.1 Axes d'analyse

L'analyse exploratoire couvre :

- statistiques descriptives ;
- distributions et boxplots ;
- corrélations ;
- cardinalités ;
- valeurs manquantes ;
- doublons ;
- anomalies métier ;
- incohérences de granularité ;
- couverture des jointures entre fichiers.

5.2 Constats principaux

- Les pays apparaissent avec des casses différentes, par exemple **France**, **france**, **FRANCE**.
- Les données temporelles sont au niveau pays-mois, alors que les destinations sont au niveau pays-destination.
- Les avis sociaux sont transactionnels et doivent être agrégés avant jointure.
- L'historique campagne est court et contient des contradictions.
- Le budget **unknown** ne doit pas être imputé arbitrairement.

6 Nettoyage et gouvernance

6.1 Règles de nettoyage

TABLE 6.1 – Décisions de nettoyage

Champ	Transformation	Justification
country	Normalisation en casse titre, règle spéciale USA	Référentiel pays commun
destination	Mapping vers noms réels de villes	Lisibilité métier et restitution exécutive
destination_original	Conservation du code source City_x	Lineage et auditabilité
month	Conversion datetime	Split temporel fiable
campaign_budget	Parsing numérique, unknown conservé en manquant	Pas d'invention de valeur
status vs ROI	Flag de contradiction	Signal de qualité et gouvernance

6.2 Mapping des destinations

Les destinations anonymisées **City_x** ont été mappées vers des villes réelles, par exemple :

- ("France", "City_17") → Paris ;
- ("Morocco", "City_39") → Fès ;
- ("USA", "City_46") → New York ;
- ("Germany", "City_46") → Düsseldorf.

La colonne **destination_original** conserve la valeur brute, tandis que **destination** contient le nom fiabilisé. Cette approche respecte la traçabilité et facilite la restitution devant un jury ou un comité métier.

7 Construction de la GOLD DATA

7.1 Granularité

La GOLD DATA finale est construite à la granularité :

Pays × Destination

Elle contient 160 lignes et 29 colonnes après enrichissement.

7.2 Variables dérivées

TABLE 7.1 – Variables dérivées principales

Variable	Intérêt métier
demand_growth	Mesure la dynamique récente de la demande pays
tourism_score	Combine attractivité, visiteurs, demande et reviews
quality_score	Combine rating source et score moyen des avis
sentiment_score	Convertit les sentiments sociaux en signal numérique
weather_penalty	Pénalise les destinations à météo défavorable
campaign_efficiency	Mesure le ROI par euro investi
forecasted_demand	Estimation de demande future destination
marketing_priority	Score final de priorisation marketing

7.3 Formule de priorisation

Le score `marketing_priority` combine :

- demande prévue ;
- qualité perçue ;
- sentiment en ligne ;
- ratio attractivité/coût ;
- efficacité campagne ;
- pénalité météo.

Ce score ne remplace pas la décision métier. Il fournit une base structurée de priorisation.

8 Partie F – Modélisation IA et forecasting temporel

8.1 Objectif de modélisation

L’objectif est de prévoir la demande touristique future par pays pour le mois suivant. La variable cible retenue est :

$$\text{target_next_period}_{c,t} = \text{demand_index}_{c,t+1}$$

où c représente le pays et t la période mensuelle.

Les visiteurs par destination ne disposent pas d’un historique mensuel. Ils sont donc utilisés comme variables explicatives contextuelles et non comme cible temporelle directe.

8.2 Type de problème IA

Il s’agit d’un problème de :

- régression supervisée ;
- prévision temporelle ;
- données structurées ;
- prédiction d’une variable quantitative continue.

Le futur ne doit jamais être utilisé pour entraîner le modèle. Le split est donc chronologique.

8.3 Feature engineering temporel

Les variables temporelles suivantes ont été créées par pays :

- `lag_1`, `lag_2`, `lag_3`, `lag_7`, `lag_14`, `lag_30` ;
- `rolling_mean_3`, `rolling_mean_7`, `rolling_mean_14`, `rolling_mean_30` ;
- `rolling_std_7`, `rolling_std_30` ;
- `rolling_min_30`, `rolling_max_30` ;
- `month`, `quarter`, `year`.

Toutes les variables glissantes utilisent un `shift(1)` avant calcul. Cela garantit qu’aucune information de la période courante ou future ne fuit dans les variables explicatives.

8.4 Approches comparées

TABLE 8.1 – Approches de forecasting comparées

Modèle	Rôle
Baseline Persistence	Prévision naïve : la prochaine valeur est égale à la valeur courante
Baseline Moving Average	Moyenne mobile des périodes précédentes
SARIMAX	Modèle statistique de série temporelle par pays avec variables exogènes
Prophet	Modèle additif temporel par pays, si librairie disponible
Random Forest + lag features	Forecasting supervisé avec variables temporelles
Gradient Boosting + lag features	Forecasting supervisé avec variables temporelles

8.5 Résultats des modèles

TABLE 8.2 – Performance des modèles

Modèle	MAE	RMSE	MAPE	R^2
Gradient Boosting + lag features	6.85	8.67	7.30%	0.86
Random Forest + lag features	7.69	9.64	8.15%	0.82
Baseline Persistence	9.94	12.16	10.70%	0.72
Baseline Moving Average	13.24	14.94	14.31%	0.57
SARIMAX	16.89	20.39	19.20%	0.20
Prophet	—	—	—	—

8.6 Choix du modèle

Le modèle retenu est **Gradient Boosting + lag features**. Il obtient la meilleure performance sur l'ensemble de test temporel avec :

- MAE = 6.85 ;
- RMSE = 8.67 ;
- MAPE = 7.30% ;
- R^2 = 0.86.

Ce modèle bat les deux baselines temporelles. Il est donc légitime de considérer que les variables temporelles enrichies apportent une valeur prédictive par rapport à une approche naïve.

8.7 Lecture critique

Les modèles Random Forest et Gradient Boosting ont été adaptés au forecasting via la création de variables de retard et de moyennes glissantes. Ils ne sont donc pas utilisés comme simples modèles tabulaires, mais comme approches de prévision supervisée temporelle.

SARIMAX et Prophet sont méthodologiquement adaptés aux séries temporelles. Toutefois, leurs performances sont limitées par la longueur d'historique disponible. Prophet n'est pas installé dans l'environnement local ; le pipeline le documente comme indisponible sans casser le notebook.

9 Moteur de recommandation métier

9.1 Contraintes intégrées

Le moteur de recommandation combine :

- prévision de demande ;
- qualité ;
- sentiment ;
- météo ;
- historique campagne ;
- coût ;
- budget marketing ;
- maximum cinq destinations par pays ;
- exclusion des destinations météo trop défavorables.

9.2 Top recommandations

TABLE 9.1 – Top 10 recommandations marketing

Pays	Destination	Priorité	Demande prévue	Budget
Morocco	Fès	0.66	20.75 M	12.1 K EUR
Japan	Hiroshima	0.58	16.63 M	10.7 K EUR
Spain	Madrid	0.55	20.52 M	10.3 K EUR
Portugal	Faro	0.54	18.83 M	10.0 K EUR
USA	Las Vegas	0.54	19.71 M	10.0 K EUR
Italy	Venice	0.53	16.46 M	9.8 K EUR
Japan	Osaka	0.53	16.38 M	9.8 K EUR
Japan	Kobe	0.52	14.32 M	9.7 K EUR
Portugal	Coimbra	0.52	13.70 M	9.6 K EUR
Morocco	Tanger	0.52	18.54 M	9.5 K EUR

9.3 Interprétation métier

Les destinations recommandées combinent forte demande attendue, qualité acceptable, sentiment positif ou neutre, météo non bloquante et budget maîtrisé. La recommandation doit être utilisée comme outil d’aide à la décision et validée par les équipes marketing, finance et locales.

10 Dashboard Streamlit

10.1 Objectif

Le dashboard a été conçu comme une plateforme exécutive interne inspirée des standards Power BI, Tableau, Snowflake et Datadog. Il ne s'agit pas d'une interface décorative, mais d'un outil de pilotage orienté décision.

10.2 Pages principales

- **Executive Overview** : KPI, carte mondiale, top pays et destinations.
- **Data Quality** : score qualité, complétude, pipeline ETL et contrôles dataset.
- **Forecast Analytics** : réel vs prédit, comparaison modèles et métriques.
- **Business Recommendations** : top destinations, budget, qualité, météo, sentiment.
- **About** : méthodologie et principes de gouvernance.

10.3 Exports

Le dashboard permet l'export :

- CSV ;
- Excel ;
- rapport PDF de management.

11 Gouvernance et dictionnaire de données

11.1 Principes de gouvernance

- Conservation des sources brutes.
- Conservation de `destination_original` pour le lineage.
- Documentation des transformations.
- Signalement des incohérences plutôt que suppression automatique.
- Dictionnaire de données exporté en Markdown et CSV.

11.2 Exemples de règles qualité

TABLE 11.1 – Exemples de règles qualité

Variable	Règle qualité
country	Non nul, harmonisé, valeur du référentiel pays
destination	Nom fiabilisé issu du mapping gouverné
destination_original	Code source conservé, non modifié
rating	Valeur numérique bornée entre 0 et 5
cost	Valeur strictement positive
weather_penalty	Mapping contrôlé good / average / bad
campaign_budget	Valeur numérique ou manquante documentée

12 Limites et biais

12.1 Limites des données

- Les visiteurs par destination ne disposent pas d'un historique temporel mensuel.
- Le signal temporel est au niveau pays, pas destination.
- Les avis sociaux peuvent être biaisés par la langue, la plateforme ou la représentativité.
- La météo est catégorielle et simplifiée.
- Les campagnes historiques sont peu nombreuses et contiennent des contradictions.
- Prophet est déclaré dans les requirements mais non installé dans l'environnement local d'exécution.

12.2 Limites des modèles

Le modèle retenu est performant sur le split temporel disponible, mais l'historique reste court. Un backtesting multi-fenêtres serait nécessaire avant industrialisation.

13 Recommandations futures

- Collecter un historique mensuel de visiteurs par destination.
- Ajouter les prix moyens, événements, vacances scolaires et saisonnalité locale.
- Mettre en place un monitoring MLOps des métriques et du drift.
- Réaliser des tests A/B sur les campagnes recommandées.
- Ajouter une validation métier par pays avant allocation budgétaire.
- Enrichir SARIMAX et Prophet avec davantage d'historique.

Conclusion

Le projet démontre une chaîne complète de valeur data : ingestion robuste, nettoyage gouverné, GOLD DATA, dictionnaire, forecasting temporel, moteur de recommandation, dashboard exécutif et documentation. La démarche ne suppose jamais que la donnée est correcte par défaut : elle audite, documente et justifie chaque transformation.

Le modèle retenu, **Gradient Boosting + lag features**, obtient les meilleures performances sur le test temporel et bat les baselines. Sa performance s'explique par l'utilisation de variables temporelles construites sans fuite de données. Les recommandations produites constituent une aide à la décision exploitable pour orienter les budgets marketing touristiques.

A Annexes techniques

A.1 Commande de lancement

```
cd project
pip install -r requirements.txt
python run_pipeline.py
streamlit run dashboard/app.py
```

A.2 Fichiers de sortie principaux

- data/gold/gold_tourism_data.csv
- data/gold/gold_tourism_data_with_forecast.csv
- data/gold/business_recommendations.csv
- reports/model_performance.csv
- reports/forecast_predictions.csv
- reports/best_model_summary.md
- reports/feature_importance.csv
- docs/data_dictionary.md
- dashboard/app.py

A.3 Extrait de la logique de cible

```
modeling_df["target_next_period"] = (
    modeling_df.groupby("country")["demand_index"].shift(-1)
)

for lag in [1, 2, 3, 7, 14, 30]:
    modeling_df[f"lag_{lag}"] = (
        modeling_df.groupby("country")["demand_index"].shift(lag)
    )
```

A.4 Extrait de rolling features sans fuite

```
shifted = modeling_df.groupby("country")["demand_index"].shift(1)

for window in [3, 7, 14, 30]:
    modeling_df[f"rolling_mean_{window}"] = (
        shifted.groupby(modeling_df["country"])
        .rolling(window, min_periods=1)
        .mean()
        .reset_index(level=0, drop=True)
    )
```